CS372 Machine Learning: Mini Project 1 (Classification)

Written & Experiment by: นพกรณ์ สงเคราะห์ 6609540023

Github: https://github.com/Slasherw/pokemon-machinelearning

1.บทนำ (Introduction)

โครงงานย่อยที่ 1 (Mini Project 1) ฉบับนี้จัดทำขึ้นเพื่อศึกษาและประยุกต์ใช้อัลกอริทึมการเรียนรู้ของเครื่อง (Machine Learning) ในงานด้านการจำแนกประเภทข้อมูล (Classification) โดยมีวัตถุประสงค์หลักเพื่อสร้าง ทดสอบ และเปรียบเทียบประสิทธิภาพของโมเดลจำแนกประเภทต่างๆ เมื่อนำมาวิเคราะห์กับชุดข้อมูลจริง

ในการศึกษาครั้งนี้ ได้เลือกใช้ชุดข้อมูลสถิติของโปเกมอน (Pokemon Stats 2025) เป็นกรณีศึกษา โดยตั้งโจทย์ปัญหาเป็นการทำนายคุณลักษณะเฉพาะของโปเกมอน (เช่น การทำนายว่าโปเกมอนตัวนั้นจัดอยู่ในกลุ่ม "ระดับตำนาน" หรือไม่ หรือการจำแนกประเภทธาตุ) โดยอาศัยตัวแปรคุณลักษณะ (Features) พื้นฐาน เช่น พลังชีวิต (HP) พลังโจมตี (Attack) พลังป้องกัน (Defense) และความเร็ว (Speed) โครงงานนี้จะครอบคลุมตั้งแต่กระบวนการสำรวจและเตรียมข้อมูล (Exploratory Data Analysis & Preprocessing) การฝึกสอนโมเดล (Model Training) ไปจนถึงการประเมินประสิทธิภาพของโมเดล (Model Evaluation) อย่างเป็นระบบ เพื่อวิเคราะห์ว่าโมเดลใดมีความเหมาะสมและแม่นยำที่สุดสำหรับชุดข้อมูลนี้

2.คำอธิบายเกี่ยวกับข้อมูล (Dataset Description)

ข้อมูลที่นำมาใช้ในการวิเคราะห์คือชุดข้อมูล Pokemon Stats 2025 (จากไฟล์ pokemon_stats_2025.csv) ซึ่งเป็นชุดข้อมูลที่รวบรวมค่าสถานะและคุณลักษณะต่างๆ ของโปเกมอน โดยมีรายละเอียดที่สำคัญสำหรับการนำไปสร้างโมเดลจำแนกประเภทดังนี้:

- ลักษณะโดยรวมของชุดข้อมูล: ข้อมูลถูกจัดเก็บในรูปแบบตาราง ประกอบด้วยข้อมูลตัวอย่าง (Instances) ของโปเกมอนแต่ละสายพันธุ์ และมีตัวแปรคุณลักษณะ (Attributes) ทั้งที่เป็นข้อมูลเชิงปริมาณและข้อมูลเชิงคุณภาพ

- ตัวแปรคุณลักษณะ (Features): แบ่งออกเป็น 2 ประเภทหลัก ได้แก่ข้อมูลเชิงปริมาณ (Numerical Features): ค่าสถานะพื้นฐานทางการต่อสู้ ซึ่งเป็นตัวเลขที่สามารถนำไปคำนวณทางคณิตศาสตร์ได้โดยตรง เช่น hp (พลังชีวิต),

  attack (พลังโจมตี), defense (พลังป้องกัน), special_attack (พลังโจมตีพิเศษ), special_defense (พลังป้องกันพิเศษ), speed (ความเร็ว), height (ส่วนสูง), weight (น้ำหนัก) และ base_experience (ค่าประสบการณ์พื้นฐาน)

- ข้อมูลเชิงคุณภาพ (Categorical Features): ข้อมูลที่เป็นหมวดหมู่หรือข้อความ เช่น name (ชื่อ), type_1 (ธาตุหลัก), type_2 (ธาตุรอง) ซึ่งข้อมูลในส่วนนี้จำเป็นต้องผ่านกระบวนการแปลงสภาพ (Encoding) ให้เป็นตัวเลขก่อนนำเข้าสู่โมเดล

- ตัวแปรเป้าหมาย (Target Variable): ในโครงงานนี้จะกำหนดตัวแปรเป้าหมาย (Class Label) ที่ต้องการให้โมเดลทำนาย เช่น การใช้คุณลักษณะความเป็นโปเกมอนระดับตำนาน (Legendary) มาเป็นเป้าหมายในการทำ Classification แบบสองคลาส (Binary Classification) ประกอบด้วยคลาส True และ False

- คุณภาพของข้อมูลและการเตรียมข้อมูล (Data Quality & Preprocessing): ข้อมูลเบื้องต้นอาจมีค่าสูญหาย (Missing Values) เช่น ในกรณีที่โปเกมอนบางตัวไม่มี type_2 จึงต้องมีการทำความสะอาดข้อมูล (Data Imputation) นอกจากนี้เนื่องจากตัวแปรเชิงปริมาณแต่ละตัวมีสเกล (Scale) ที่แตกต่างกัน เช่น น้ำหนักกับความเร็ว จึงอาจต้องมีการทำ Normalization หรือ Standardization เพื่อให้โมเดลสามารถเรียนรู้ได้อย่างมีประสิทธิภาพสูงสุด

3. หลักการและขั้นตอน การสกัด การเลือก และการเตรียมลักษณะ

ในการวิเคราะห์ชุดข้อมูล Pokemon Stats 2025 ได้มีการดำเนินกระบวนการเตรียมข้อมูลและการคัดเลือกคุณลักษณะ (Feature Engineering & Selection) เพื่อให้ข้อมูลมีความพร้อมสูงสุดก่อนนำเข้าสู่แบบจำลอง โดยมีขั้นตอนปฏิบัติดังนี้

3.1 การเตรียมข้อมูล **(Data Preprocessing)** เนื่องจากชุดข้อมูลตั้งต้นมีความไม่สมบูรณ์และมีข้อมูลต่างประเภทกัน จึงได้ทำการปรับปรุงคุณภาพข้อมูลดังนี้

- การจัดการค่าสูญหาย **(Missing Value Handling):** ในคุณลักษณะ type_2 (ธาตุรอง) มีค่าสูญหายในกรณีที่โปเกมอนมีเพียงธาตุเดียว จึงได้ทำการเติมค่าสูญหายด้วยคำว่า 'none' เพื่อให้แบบจำลองสามารถประมวลผลได้อย่างต่อเนื่อง
- การแปลงข้อมูล **(Data Encoding):** คุณลักษณะประเภทข้อความ ได้แก่ type_1 และ type_2 ถูกแปลงให้อยู่ในรูปแบบตัวเลข (Label Encoding) เพื่อให้แบบจำลองทางคณิตศาสตร์สามารถตีความได้
- การกำจัดข้อมูลรบกวนและข้อมูลที่ครอบงำ **(Noise & Dominant Feature Removal):** ได้ทำการตัดคุณลักษณะที่ใช้สำหรับระบุตัวตน (Identifier) เช่น pokedex_id และ name ออก นอกจากนี้ จากการทดลองเบื้องต้นพบว่า base_experience เป็นคุณลักษณะที่ครอบงำผลลัพธ์ (Dominant Feature) ซึ่งอาจทำให้เกิดปัญหาข้อมูลรั่วไหล (Data Leakage) จึงตัดสินใจตัดคุณลักษณะนี้ออกเพื่อบังคับให้แบบจำลองเรียนรู้จากค่าสถานะการต่อสู้ (Combat Stats) อย่างแท้จริง
    - ผลลัพธ์ของการทำ feature_importance โดยมี feature base_experience

```
Baseline AUC (All Features): 0.9907
```

```
AUC after retraining (2/3 features): 0.9907
```

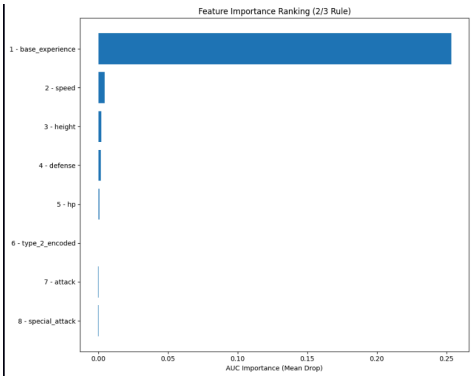

- ผลลัพธ์ของการทำ feature_importance โดยการตัด feature base_experience ออก

```
Baseline AUC (All Features): 0.9352
```

```
AUC after retraining (2/3 features): 0.9444
```

```
=====================================
AUC-Based Permutation Importance Ranking
=====================================
   rank          feature  auc_importance_mean  auc_importance_std
0     1               hp             0.080833            0.032051
1     2          defense             0.041574            0.013780
2     3           height             0.024074            0.014012
3     4            speed             0.013611            0.025949
4     5  special_defense             0.005741            0.004589
5     6   special_attack             0.002222            0.018524
6     7           attack             0.001389            0.012905
```

- การปรับสเกลข้อมูล **(Standardization):** คุณลักษณะเชิงปริมาณแต่ละตัวมีช่วงค่าที่แตกต่างกัน เช่น weight มีค่าหลักพัน ในขณะที่ height มีค่าหลักสิบ จึงได้ใช้ StandardScaler เพื่อปรับให้ข้อมูลทุกตัวมีค่าเฉลี่ยเป็น 0 และส่วนเบี่ยงเบนมาตรฐานเป็น 1 ป้องกันไม่ให้แบบจำลองเอนเอียงไปยังคุณลักษณะที่มีค่าตัวเลขสูง

3.2 การคัดเลือกคุณลักษณะด้วย **Tree-based** และ **Permutation Importance**
เนื่องจากข้อมูลมีคุณลักษณะจำนวนมาก จึงได้ใช้เทคนิค Tree-based ผนวกกับ Permutation Importance บนแบบจำลอง XGBoost เพื่อประเมินความสำคัญของ

คุณลักษณะ จากผลการวิเคราะห์พบว่า คุณลักษณะที่มีความสำคัญสูงสุด **3** อันดับแรก **(Top 3 Features)** ได้แก่:

1. **HP:** เป็นคุณลักษณะที่สำคัญที่สุด เนื่องจากโปเกมอนระดับตำนานมักจะถูกออกแบบให้มีพลังชีวิตพื้นฐานที่สูงมากเพื่อความทนทานในการต่อสู้
2. **Defense:** ค่าพลังป้องกันที่สูงเป็นอีกหนึ่งปัจจัยที่แยกโปเกมอนระดับตำนานออกจากโปเกมอนทั่วไป
3. **Height:** สอดคล้องกับลักษณะทางกายภาพที่โปเกมอนระดับตำนานส่วนใหญ่มักจะมีขนาดตัวที่ใหญ่โตและโดดเด่นกว่าปกติ

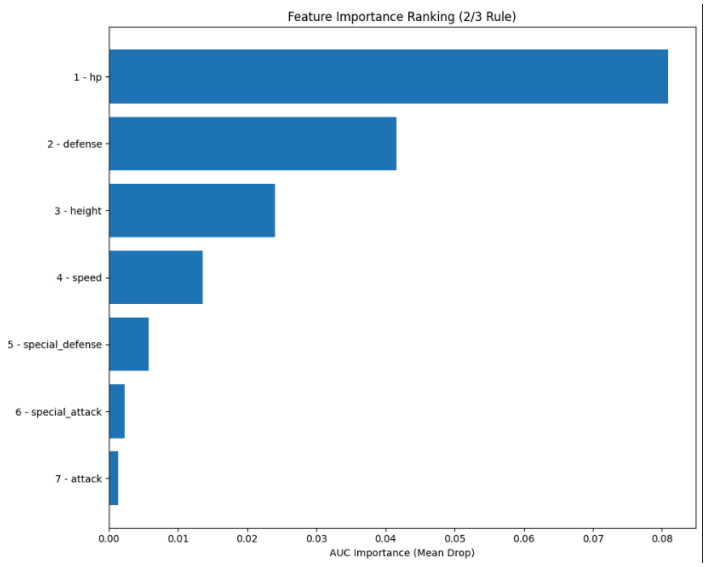

3.3 การหาจำนวนคุณลักษณะที่เหมาะสม **(Optimal Feature Selection)** เพื่อลดความซับซ้อนของแบบจำลองและป้องกันปัญหา Overfitting จึงได้นำกระบวนการ Nested Cross-Validation มาใช้เพื่อหาจำนวนคุณลักษณะที่เหมาะสมที่สุด (Optimal Number of Features) โดยจำลองการแบ่งข้อมูลทดสอบแบบ 5-Fold Outer CV และ 3-Fold Inner CV

- ผลลัพธ์: จากการทดสอบพบว่า จำนวนคุณลักษณะที่เหมาะสมที่สุดที่ให้ค่าความแม่นยำสูงและมีความเสถียร (อ้างอิงจากค่ามัธยฐานของ Best k) คือ **5** คุณลักษณะ โดยให้ค่าความแม่นยำ (Nested CV Accuracy) เฉลี่ยสูงถึง 96.49%

3.4 คุณลักษณะที่เหลือหลังจากทำขั้นตอน **Feature Selection** เมื่อดึงคุณลักษณะที่มีความสำคัญสูงสุด 5 อันดับแรก จากข้อมูลทั้งหมด พบว่าคุณลักษณะที่ถูกคัดเลือกเพื่อนำไปใช้ในการฝึกสอนแบบจำลองในขั้นตอนถัดไป (Selected Features) ประกอบด้วย:

1. hp
2. defense
3. height
4. speed
5. Special_defense

4. เทคนิคที่ใช้ และการออกแบบการทดลอง

4.1 การจัดเตรียมข้อมูลสำหรับแบบจำลอง **(Data Splitting)** เพื่อประเมินความสามารถในการเรียนรู้และการพยากรณ์ข้อมูลใหม่ ได้ทำการแบ่งชุดข้อมูลออกเป็น 2 ส่วนในอัตราส่วน **80/20** ดังนี้

- ชุดข้อมูลสำหรับฝึกสอนและทวนสอบ **(Train & Cross-Validation Set):** คิดเป็น 80% ของข้อมูลทั้งหมด ใช้สำหรับให้แบบจำลองเรียนรู้และค้นหาพารามิเตอร์ที่ดีที่สุด
- ชุดข้อมูลสำหรับทดสอบ **(Evaluation/Test Set):** คิดเป็น 20% ของข้อมูลทั้งหมด ข้อมูลชุดนี้ถูกแยกเก็บไว้และไม่นำมาใช้ในขั้นตอนการฝึกสอนเลย เพื่อใช้ทดสอบปัญหาการเรียนรู้จำ (Overfitting)
- เทคนิคที่ใช้เพิ่มเติม: ใช้พารามิเตอร์ stratify ในการแบ่งข้อมูล เพื่อรักษาสัดส่วนของโปเกมอนระดับตำนานในชุด Train และ Test ให้มีอัตราส่วนเท่ากัน ป้องกันปัญหาข้อมูลเสียสมดุลในขั้นตอนการวัดผล

4.2 เทคนิคการจำแนกประเภทที่นำมาเปรียบเทียบ ในการทดลองนี้ได้เลือกใช้อัลกอริทึมการเรียนรู้ของเครื่อง 3 เทคนิค ได้แก่

1. **K-Nearest Neighbors (KNN):** เป็นแบบจำลองที่ใช้ความคล้ายคลึงของระยะทาง ข้อดีคือเข้าใจง่ายและทำงานได้ดีกับข้อมูลที่มีจำนวน Feature ไม่มากนัก แต่มีข้อเสียคือใช้เวลาคำนวณนานหากข้อมูลมีขนาดใหญ่
2. **XGBoost:** เป็นเทคนิค Tree-based แบบ Ensemble ขั้นสูง ข้อดีคือมีความแม่นยำสูงมากและสามารถจัดการกับความสัมพันธ์ของข้อมูลที่ซับซ้อน (Non-linear) ได้ดี แต่ข้อเสียคือมีพารามิเตอร์ที่ต้องปรับจูนจำนวนมากและอธิบายผลลัพธ์ (Black-box) ได้ยากกว่า Tree ปกติ
3. **Neural Network (MLP):** เครือข่ายประสาทเทียมที่จำลองการทำงานของสมองมนุษย์ ข้อดีคือสามารถเรียนรู้รูปแบบที่ซับซ้อนมากๆ ได้ แต่ข้อเสียคือต้องการทรัพยากร

การประมวลผลสูงและอาจเกิด Overfitting ได้ง่ายหากไม่ได้ปรับจูนโครงสร้าง (Hidden Layers) อย่างเหมาะสม

4.3 การค้นหาค่าพารามิเตอร์ที่ดีที่สุด **(Hyperparameter Tuning)** เพื่อให้แบบจำลองแต่ละตัวดึงศักยภาพสูงสุดออกมาใช้งาน จึงได้ใช้เทคนิค **Grid Search CV (5-Fold)** บนชุดข้อมูล Train Set เพื่อค้นหาพารามิเตอร์ (Best Parameter Set) ที่ให้ค่า F1-Score สูงที่สุด โดยมีผลลัพธ์พารามิเตอร์ที่ถูกเลือกดังนี้:

- **KNN:**

  Best Params (KNN): {'n_neighbors': 3, 'weights': 'uniform'}

- **XGBoost:**

  Best Params (XGBoost): {'learning_rate': 0.05, 'max_depth': 3, 'n_estimators': 200}

- **Neural Network:**

  Best Params (Neural Network): {'activation': 'tanh', 'hidden_layer_sizes': (100,), 'learning_rate_init': 0.001}

5. การประเมินและเปรียบเทียบผลลัพธ์

จากการทดลองฝึกสอนและประเมินประสิทธิภาพของแบบจำลองทั้ง 3 ชนิด บนชุดข้อมูลทดสอบ (Test Set) พบว่าผลลัพธ์มีความสอดคล้องกันดังนี้:

1. ประสิทธิภาพภาพรวม: แบบจำลอง **XGBoost** และ **Neural Network (MLP)** มีประสิทธิภาพสูงสุดเท่ากัน โดยให้ค่าความแม่นยำรวม (Accuracy) สูงถึง 98.00% และค่า F1-Score ที่ 0.6667 ซึ่งเหนือกว่าแบบจำลอง KNN ที่ได้ค่า F1-Score เพียง 0.5000 อย่างชัดเจน
2. ความแม่นยำในการระบุตัวตน **(Precision):** จุดเด่นของทั้ง XGBoost และ Neural Network คือการให้ค่า Precision สูงถึง 1.0000 หมายความว่าแบบจำลองทั้งสองมีความมั่นใจสูงมาก หากระบบทำนายว่าโปเกมอนตัวใดเป็นระดับตำนาน การทำนายนั้นจะถูกต้อง 100% โดยไม่มีข้อผิดพลาด (Zero False Positives)
3. ปัญหาที่พบ: ค่า Recall ของทุกแบบจำลองอยู่ที่ 0.5000 แสดงให้เห็นว่าแบบจำลองยังคงมีความระมัดระวังในการทำนายสูง ส่งผลให้มีโปเกมอนระดับตำนานบางตัวหลุดรอดจากการตรวจจับไปได้ (False Negatives) ซึ่งอาจเป็นผลสืบเนื่องมาจากปัญหาข้อมูลสูญเสียสมดุล (Imbalanced Data) ที่มีโปเกมอนระดับตำนานเป็นสัดส่วนที่น้อยมากในชุดข้อมูล

```
กำลังเทรนโมเดล KNN...
🌟 Best Params (KNN): {'n_neighbors': 3, 'weights': 'uniform'}
📊 ผลการประเมิน KNN (Evaluation Set):
Accuracy:  0.9600
Precision: 0.5000
Recall:    0.5000
F1-Score:  0.5000
----------------------------------------
```

```
กำลังเทรนโมเดล XGBoost...
🌟 Best Params (XGBoost): {'learning_rate': 0.05, 'max_depth': 3, 'n_estimators': 200}
📊 ผลการประเมิน XGBoost (Evaluation Set):
Accuracy:  0.9800
Precision: 1.0000
Recall:    0.5000
F1-Score:  0.6667
----------------------------------------
```

```
กำลังเทรนโมเดล Neural Network...
🌟 Best Params (Neural Network): {'activation': 'tanh', 'hidden_layer_sizes': (100,), 'learning_rate_init': 0.001}
📊 ผลการประเมิน Neural Network (Evaluation Set):
Accuracy:  0.9800
Precision: 1.0000
Recall:    0.5000
F1-Score:  0.6667
----------------------------------------
```

ผลการทดลองเพิ่มเติม

ในการทดลองเบื้องต้น พบปัญหาว่าโมเดล Neural Network ไม่สามารถลู่เข้าสู่ค่าที่เหมาะสมที่สุดได้ (Failed to converge) และให้ค่า F1-Score เป็น 0 ซึ่งเกิดจากการที่ชุดข้อมูลมีปัญหาความไม่สมดุลของคลาส (Class Imbalance) อย่างรุนแรง และข้อมูลสถานะของโปเกมอนมีช่วงสเกลที่แตกต่างกัน จึงได้ดำเนินการแก้ไขโดยการทำ Standardization ให้กับข้อมูลชุด Train และ Test แยกกัน รวมถึงเพิ่มจำนวนรอบการเรียนรู้ (Max Iterations) ทำให้แบบจำลองสามารถแยกแยะคลาสส่วนน้อย (Minority Class) ได้ดีขึ้น

<u>ผลลัพธ์จากการทดสอบโมเดลโดยไม่ได้ทำการ Standardization</u>

```
กำลังเทรนโมเดล KNN...
🌟 Best Params (KNN): {'n_neighbors': 3, 'weights': 'uniform'}
📊 ผลการประเมิน KNN (Evaluation Set):
Accuracy:  0.9600
Precision: 0.5000
Recall:    0.5000
F1-Score:  0.5000
----------------------------------------
```

```
กำลังเทรนโมเดล XGBoost...
🌟 Best Params (XGBoost): {'learning_rate': 0.05, 'max_depth': 3, 'n_estimators': 200}
📊 ผลการประเมิน XGBoost (Evaluation Set):
Accuracy:  0.9800
Precision: 1.0000
Recall:    0.5000
F1-Score:  0.6667
----------------------------------------
```

```
🌟 Best Params (Neural Network): {'activation': 'relu', 'hidden_layer_sizes': (50,), 'learning_rate_init': 0.001}
📊 ผลการประเมิน Neural Network (Evaluation Set):
Accuracy:  0.9600
Precision: 0.0000
Recall:    0.0000
F1-Score:  0.0000
----------------------------------------
```

6. สรุปผลการศึกษา (Conclusion)

โครงงานนี้มีวัตถุประสงค์เพื่อสร้างและเปรียบเทียบประสิทธิภาพของแบบจำลองการเรียนรู้ของเครื่อง (Machine Learning) ในการจำแนกประเภทโปเกมอนระดับตำนาน (Legendary Pokémon) จากค่าสถานะการต่อสู้และลักษณะทางกายภาพ โดยผ่านกระบวนการเตรียมข้อมูล (Data Preprocessing) การปรับสเกลมาตรฐาน (Standardization) และการคัดเลือกคุณลักษณะ (Feature Selection) อย่างเป็นระบบ จนได้คุณลักษณะที่มีอิทธิพลสูงสุด 5 ประการ ได้แก่ HP, Defense, Height, Speed และ Special Defense นำมาใช้เป็นปัจจัยในการฝึกสอนแบบจำลอง

จากการทดลองเปรียบเทียบแบบจำลองทั้ง 3 ชนิด ได้แก่ K-Nearest Neighbors (KNN), XGBoost และ Neural Network (MLP) ร่วมกับการค้นหาพารามิเตอร์ที่ดีที่สุดด้วยเทคนิค Grid Search สามารถสรุปผลได้ดังนี้:

1. แบบจำลองที่มีประสิทธิภาพสูงสุด: แบบจำลอง **XGBoost** และ **Neural Network** ทำผลงานได้ดีที่สุดและมีประสิทธิภาพเทียบเท่ากัน โดยให้ค่าความแม่นยำรวม (Accuracy) บนชุดข้อมูลทดสอบสูงถึง **98.00%** และให้ค่า F1-Score ที่ **0.6667** ซึ่งเป็นผลลัพธ์ที่เหนือกว่าแบบจำลอง KNN (F1-Score 0.5000) อย่างชัดเจน
2. ความแม่นยำแบบไร้ข้อผิดพลาด **(Perfect Precision):** จุดเด่นที่สำคัญที่สุดของ XGBoost และ Neural Network ในโครงงานนี้คือ การให้ค่า Precision สูงถึง **1.0000 (100%)** ซึ่งแสดงให้เห็นว่าแบบจำลองมีความรัดกุมสูงมาก หากแบบจำลองตัดสินใจว่าโปเกมอนตัวใดคือระดับตำนาน การตัดสินใจนั้นถูกต้องเสมอโดยไม่มีการทำนายผิดพลาด (Zero False Positive)
3. ข้อจำกัดของโครงงานและข้อเสนอแนะ: แม้แบบจำลองจะมีความแม่นยำสูง แต่ยังคงพบข้อจำกัดในด้านค่าความครอบคลุม (Recall) ซึ่งอยู่ที่ระดับ 0.5000 (50%) หมายความว่าแบบจำลองยังพลาดการตรวจจับโปเกมอนระดับตำนานไปครึ่งหนึ่ง สาเหตุหลักของปัญหานี้เกิดจากลักษณะของชุดข้อมูลที่มี ความไม่สมดุลของคลาสอย่างรุนแรง **(Extreme Class Imbalance)** เนื่องจากโปเกมอนระดับตำนานมีสัดส่วนที่น้อยมากเมื่อเทียบกับโปเกมอนทั่วไป